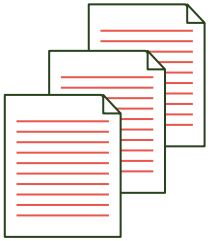

Otimizando a importação de candidatos do SISU no processo de matrícula da UFRJ

Luiz Carlos F. Carvalho
Vitória M. C. Chaves

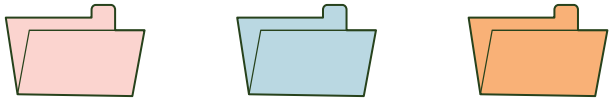

Start

Contextualizando o problema

Em todas as edições do SISU, a UFRJ recebe um CSV com os candidatos aprovados na chamada regular e os da lista de espera. Este arquivo sempre possui entre 8 e 20 mil linhas com possíveis futuros alunos da UFRJ.

Arquivo CSV	O arquivo geralmente possui informações dos candidatos, que são necessárias para dar início ao processo de matrícula na universidade ou participarem da lista de espera.
Importar Candidatos	Após o recebimento do arquivo, iniciamos a etapa de importar esses candidatos para o banco de dados, mas ainda sem convertê-los nas entidades do banco.
Converter Candidatos	*Após a importação ser efetuada, convertemos esses candidatos nas entidades do banco e verificamos se já existem dados existentes ou se são novos e assim, os convertemos para as entidades do banco de dados.*
Implantar Candidatos	*Após a etapa de conversão ser realizada, iniciamos o processo de implantação, que consiste na persistência dos dados no banco, onde os candidatos já estarão prontos para dar início ao processo de matrícula na UFRJ.*

Etapas da solução concorrente

01

Pré-processamento

Carrega um cache de dados já existentes de candidatos que já participaram de processos anteriores.

02

Processamento

Etapa que realiza a conversão dos dados para as entidades do banco de dados.

03

Persistência

Etapa que armazena os dados no banco de dados.

Testes de Corretude

SQL - Except
SQL - Count

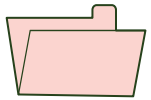

Utilizamos tabelas temporárias para verificar se o resultado concorrente efetuou o processamento dos dados de forma correta.
Ou seja, o comando **except** do SQL retorna linhas distintas da consulta de entrada à esquerda que não são produzidas pela consulta de entrada à direita. Dessa forma, conseguimos verificar a diferença dos resultados concorrentes para o sequencial nos diversos conjuntos de dados utilizados. Já o **count**, serve para verificarmos se todos os dados que foram processados foram inseridos no banco de dados.

Resultados dos testes de desempenho

Etapa 1 - Pré-Processamento (maior gargalo)

Tamanho	Threads	Pre-Processamento (s)
1000	1	52
	4	50,6
	8	50,6
	16	50,8
4000	1	208,2
	4	203
	8	202
	16	202
8842	1	460,2
	4	447,6
	8	447,2
	16	447,4

Lotes

Utilizamos lotes de 1000, 4000 e 8842 dados

Problemas

Usamos um banco de dados SQL Server 2005 e após muitas tentativas de executar queries paralelas, ainda assim, cada execução foi realizada de forma sequencial.

Resultados dos testes de desempenho

Etapa 2 - Processamento

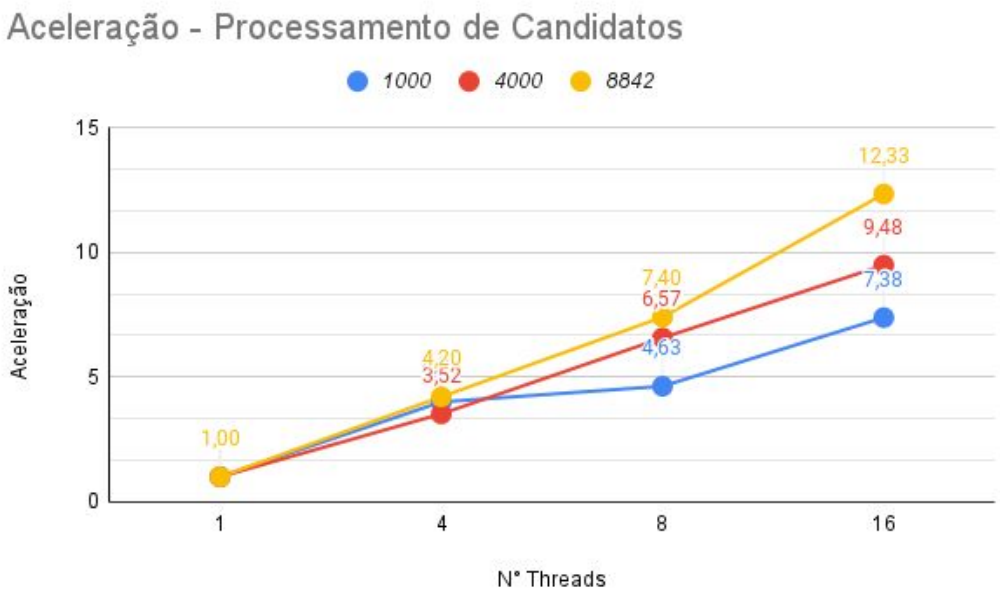

Lotes

Foram usados lotes de 1000, 4000 e 8842 dados.
Maior aceleração: 12,33 para 8842 dados e 16 threads.

Testes

Realizamos 5 execuções para cada conjunto de testes e estimamos a média dos tempos sequencial (com 1 thread) e concorrente.

Resultados dos testes de desempenho

Etapa 2 - Processamento

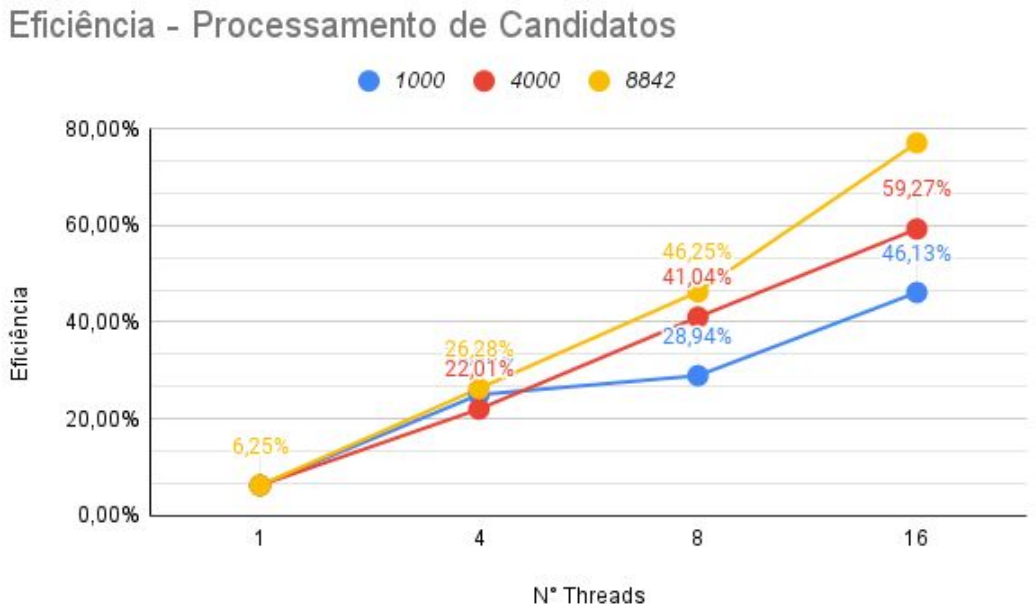

Lotes

Foram usados lotes de 1000, 4000 e 8842 dados. Maior eficiência: 77,08% para 8842 dados e 16 threads.

Testes

Realizamos 5 execuções para cada conjunto de testes e estimamos a média dos tempos sequencial (com 1 thread) e concorrente.

Resultados dos testes de desempenho

Etapa 3 - Persistência

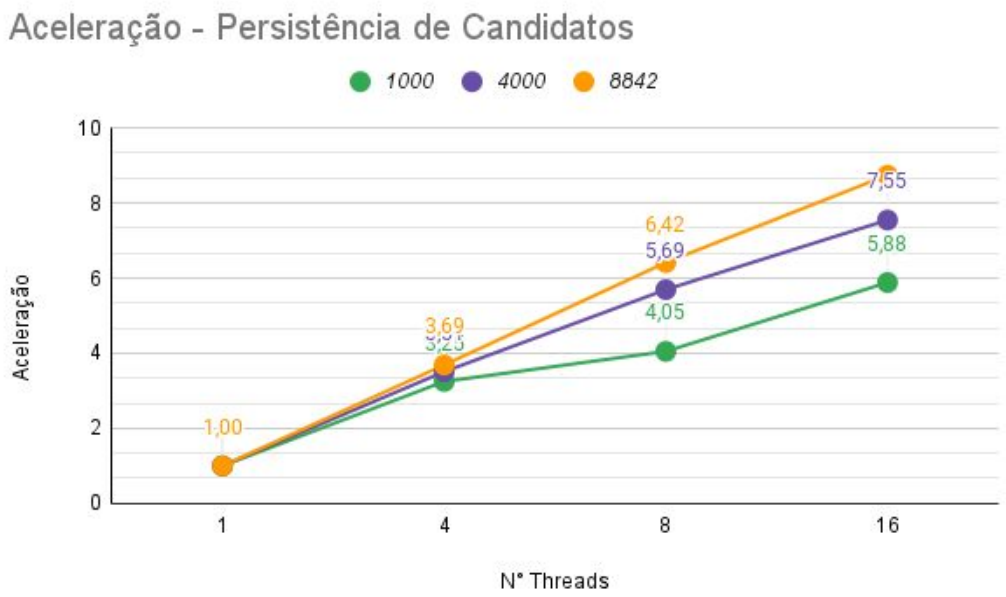

Lotes

Foram usados lotes de 1000, 4000 e 8842 dados.
Maior aceleração: 7,55 para 8842 dados e 16 threads.

Testes

Realizamos 5 execuções para cada conjunto de testes e estimamos a média dos tempos sequencial (com 1 thread) e concorrente.

Resultados dos testes de desempenho

Etapa 3 - Persistência

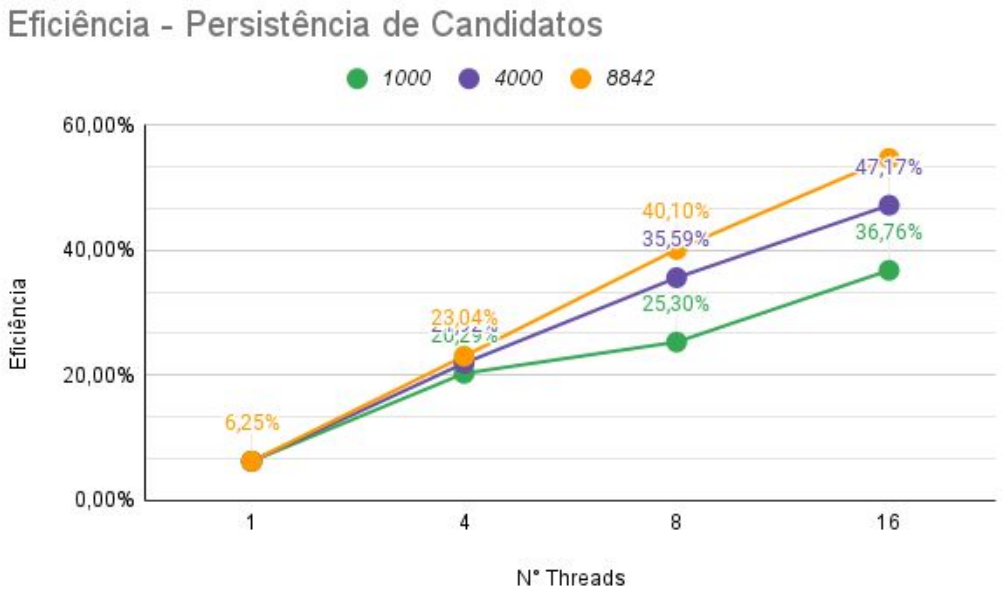

Lotes

Foram usados lotes de 1000, 4000 e 8842 dados.
Maior eficiência: 47,17% para 8842 dados e 16 threads.

Testes

Realizamos 5 execuções para cada conjunto de testes e estimamos a média dos tempos sequencial (com 1 thread) e concorrente.

Obrigado

Accept

Cancel